

Centrage et reduction

on pose $z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_{xj}}$

$\bar{x} = 0 \Rightarrow X$ variable centree
 $s_x = 1 \Rightarrow X$ reduit
 $X^* = \frac{x_i - \bar{x}}{s_x}$

ind	\bar{x}_1	\bar{x}_2	...	\bar{x}_p
ind ₁	z_{11}	z_{12}	...	z_{1p}
...				
ind _n	z_{n1}	z_{np}
\bar{x}_j	0	0	...	0
s_{xj}	1	1	...	1

Le tableau sous sa forme matricielle

$$Z = \begin{pmatrix} z_{11} & z_{12} & \dots & z_{1p} \\ z_{21} & z_{22} & \dots & z_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ z_{n1} & z_{n2} & \dots & z_{np} \end{pmatrix} \in \mathbb{R}^{n \times p}$$

Z est une matrice centree reduite.

variable centree reduite :

• centre de gravite $y = (0, 0, 0, \dots, 0)^T$

• Inertie totale : $I_{tot}(y=0) = \sum_{j=1}^p V(X_j^*)$

$$= \underbrace{1 + \dots + 1}_{p \text{ fois}} = p$$

Matrice de correlation R.

$$R = \frac{1}{n} Z^T \cdot Z$$

• ou bien en utilisant $\bar{x}_j^* = 0$ et $s_{xj}^* = 1$

$$r(x_i^*, x_k^*) = \frac{1}{n} \sum_{j=1}^n z_{ji} z_{jk} \text{ avec } r_{jj} \text{ les valeurs de } Z$$

$$r_{ij} = r(x_i, x_j) = \frac{\text{Cov}(x_i, x_j)}{s_{x_i} \times s_{x_j}}$$

$$r_{ij} = r(x_i, x_j) = r(x_j, x_i) = r_{ji}$$


$$r_{ii} = \frac{\text{Cov}(x_i, x_i)}{s_{x_i}^2} = \frac{V(x_i)}{V(x_i)} = 1$$

Produit Matriciel

$$A \in \mathbb{R}^{n \times m} \quad B \in \mathbb{R}^{m \times p}$$

$$A \cdot B \in \mathbb{R}^{n \times p} \quad (n \times m)(m \times p)$$

Interpretation de correlation



Les composantes principales (facteurs)

$$ly_j = Z \cdot v_j$$

avec Z matrice centrée réduite

v_j : Les vecteurs propres de R .

Choix des composantes principales

Wavelength	Inertie expliquée (%)	Inertie cumulée
λ_1	$\frac{\lambda_1}{P} \times 100$	$\frac{\lambda_1}{P} \times 100$
λ_2	$\frac{\lambda_2}{P} \times 100$	$(\frac{\lambda_1}{P} + \frac{\lambda_2}{P}) \times 100$
\vdots	\vdots	\vdots
λ_p	$\frac{\lambda_p}{P} \times 100$	$(\frac{\lambda_1}{P} + \frac{\lambda_2}{P} + \dots + \frac{\lambda_p}{P}) \times 100$

+ Comment choisir les facteurs à retenir?

Extraire les facteurs de façon à expliquer au moins 80% de la variance totale.

$$R v_j = \lambda_j v_j$$

ACP:

Matrice: $A = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1j} & \dots & a_{1m} \\ a_{21} & & & & & \\ \vdots & & & & & \\ a_{n1} & & & & & a_{nm} \end{pmatrix} \in \mathbb{R}^{n \times m}$

avec n : nombre de ligne
 m : nombre de colonne

Matrice transposée: A^T

exp $A = \begin{pmatrix} 5 & 6 & 4 \\ 2 & 19 & 10 \end{pmatrix} \quad A^T = \begin{pmatrix} 5 & 2 \\ 6 & 19 \\ 4 & 10 \end{pmatrix}$

transposé d'un vecteur-colonne est un vecteur ligne.
 $x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}, \quad x^T = (x_1 \dots x_n)$

Tableau individus/variables

ind	x_1	x_2	...	x_p
ind 1				
ind n				
Indice				
reco				

Le tableau sous forme matricielle
 $X = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1p} \\ \vdots & \vdots & & \vdots \\ x_{n1} & \dots & \dots & x_{np} \end{pmatrix} \in \mathbb{R}^{n \times p}$

Chaque individu est décrit par p variables, formant un vecteur de dimension p :
 $\text{ind } i = (x_{i1}, x_{i2}, \dots, x_{ip})^T = \begin{pmatrix} x_{i1} \\ \vdots \\ x_{ip} \end{pmatrix}$

La distance entre deux individus

$$d(\text{ind } i, \text{ind } k) = \sqrt{\sum_{j=1}^p (x_{ij} - x_{kj})^2}$$

$$\text{ind } i = (x_{i1}, x_{i2}, \dots, x_{ip})^T$$

$$\text{ind } k = (x_{k1}, \dots, x_{kp})^T$$

exp: $\text{ind}_1 (5, 17, 6) \quad \text{ind}_2 (10, 2, 6)$

$$d(\text{ind}_1, \text{ind}_2) = \sqrt{(10-5)^2 + (2-17)^2 + (6-6)^2} = 15,81$$

Le centre de gravité: $g = (\bar{x}_1, \bar{x}_2, \bar{x}_3)^T$

Inertie totale: $I_{\text{tot}}(g) = \sum_{j=1}^p V(x_j)$